

FinSent: Sentiment Analysis per Insight Finanziari Automatizzati

Irene Gaita
Mat: 0522501839
i.gaita1@studenti.unisa.it

Mario Cicalese
Mat: 0522501799
m.cicalese21@studenti.unisa.it

ABSTRACT

Questo progetto affronta il compito della sentiment analysis applicata a notizie finanziarie in lingua inglese riguardanti società quotate nell'indice OMX Helsinki. È stato utilizzato un dataset di circa 5000 frasi, annotate manualmente da 16 valutatori in base all'impatto percepito sul prezzo delle azioni (positivo, negativo o neutrale). Dopo una fase di pre-processing testuale, implementata in versioni leggere e aggressive, sono stati esplorati vari metodi di embedding (Word2Vec, BERT, SBERT, FinBERT) e modelli di classificazione supervisionata (SVM, Random Forest, MLP, Logistic Regression). Il miglior risultato nella fase baseline è stato ottenuto da una SVM su embedding FinBERT, con un'accuracy dell'84.9%. In una fase successiva, l'impiego di modelli transformer pre-addestrati ha portato a un miglioramento significativo, con il modello deberta-v3-ft che ha raggiunto un'accuratezza prossima al 99% dopo fine-tuning. Inoltre, è stato integrato BERTopic per un'analisi tematica del contenuto testuale. L'analisi degli errori ha evidenziato criticità legate all'ambiguità semantica di alcune frasi. Il progetto conferma l'efficacia dei modelli linguistici pre-addestrati per applicazioni di sentiment analysis nel dominio finanziario.

1 INTRODUZIONE

L'analisi automatica del sentiment nelle notizie finanziarie rappresenta un ambito di crescente interesse all'interno della ricerca applicata all'economia computazionale e al machine learning. Le informazioni veicolate attraverso articoli di stampa, report aziendali e comunicati economici possono influenzare in modo significativo le scelte degli investitori e, di conseguenza, l'andamento dei mercati. In tale contesto, lo sviluppo di strumenti in grado di interpretare il contenuto testuale delle notizie dal punto di vista dell'impatto percepito sul valore dei titoli risulta strategico per supportare decisioni d'investimento più rapide, consapevoli e scalabili.

Il presente progetto si concentra sulla costruzione e valutazione di un sistema di classificazione automatica del sentiment espresso in notizie riguardanti società quotate nell'indice OMX Helsinki. Il dataset, ottenuto tramite web scraping da fonti in lingua inglese come LexisNexis, è composto da circa 5000 frasi annotate manualmente da un gruppo di 16 valutatori. Ogni frase è stata etichettata come positiva, negativa o neutrale in funzione del potenziale impatto che l'informazione potrebbe generare sul prezzo delle azioni, simulando la prospettiva di un investitore al dettaglio. Questa fase di annotazione umana conferisce particolare valore al dataset, rendendolo adatto sia all'addestramento che alla validazione di modelli di apprendimento automatico.

Tra le principali sfide affrontate vi sono la complessità linguistica dei testi finanziari, spesso caratterizzati da terminologia tecnica e da una struttura sintattica articolata, nonché l'ambiguità semantica di alcune frasi, che possono assumere significati differenti a

seconda del contesto. Un'ulteriore criticità riguarda lo sbilanciamento delle classi nel dataset, con una marcata prevalenza della classe "neutrale", che potrebbe influenzare negativamente la capacità predittiva del modello. Al fine di arricchire l'analisi e ottenere una rappresentazione tematica del contenuto testuale, è stato inoltre impiegato BERTopic, un algoritmo di topic modeling basato su embeddings semantici, che ha permesso di identificare i principali argomenti trattati nelle notizie e di analizzare la distribuzione del sentiment all'interno dei diversi topic individuati. Il successo del sistema verrà valutato attraverso metriche di classificazione come accuracy, precision, recall e F1-score. Infine, verranno considerati anche aspetti legati alla scalabilità e all'efficienza computazionale, al fine di rendere il modello adatto a scenari operativi in tempo reale.

2 METODOLOGIA

La presente sezione descrive in dettaglio la metodologia adottata per la costruzione del sistema di analisi del sentiment, articolata in tre fasi principali: analisi e il preprocessing dei dati, la definizione delle configurazioni di classificazione del sentiment, e la selezione delle caratteristiche testuali più rilevanti per l'addestramento dei modelli. Si parte con un'analisi esplorativa del dataset, finalizzata a comprenderne la struttura di base, con particolare attenzione alla distribuzione delle classi, alla lunghezza delle frasi e alla frequenza delle parole nei testi originali. Tutte le osservazioni presentate in questa fase sono basate sulla versione grezza del corpus, prima dell'applicazione di qualunque intervento di pulizia o bilanciamento, in modo da restituire un quadro oggettivo e non distorto dei dati. L'analisi include anche una valutazione degli squilibri tra le classi e dell'eventuale presenza di outlier, aspetti che influenzano direttamente le strategie adottate nelle fasi successive. A seguire, si discuteranno le configurazioni di classificazione considerate e i criteri impiegati per la selezione delle feature testuali, con l'obiettivo di massimizzare la capacità predittiva dei modelli riducendo al contempo la dimensionalità del problema.

2.1 Dataset

In questa sezione si andrà a discutere della struttura e delle caratteristiche principali del dataset attraverso una prima fase di analisi esplorativa dei dati (EDA). L'obiettivo è comprendere la composizione delle classi di sentiment, la distribuzione delle lunghezze delle frasi e la frequenza delle parole più ricorrenti nel testo originario. Tutte le analisi presentate in questa sezione sono state condotte prima dell'applicazione di qualsiasi tecnica di preprocessing o bilanciamento, in modo da offrire una visione fedele e imparziale della natura grezza dei dati. Verranno inoltre valutati eventuali squilibri tra le classi e la presenza di outlier, aspetti rilevanti per le scelte da adottare nelle successive fasi di pulizia e modellazione del testo.

2.2 Descrizione del dataset originale

Il dataset "FinancialPhraseBank" utilizzato in questo progetto, disponibile pubblicamente su Kaggle ¹ e creato per l'analisi del sentiment delle notizie finanziarie, trae origine da un'attenta raccolta e selezione di articoli finanziari.

La sua creazione, ad opera di Malo et al. come descritto nel lavoro "Good debt or bad debt: Detecting semantic orientations in economic texts," ha impiegato una metodologia precisa.

Inizialmente, gli autori hanno proceduto alla raccolta automatica di notizie tramite uno web scraper, estraendo dati dal database LexisNexis ² per la creazione del corpus. L'attenzione si è concentrata su articoli in lingua inglese relativi alle aziende quotate sull'OMX Helsinki ³.

Successivamente, è stata implementata una fase di filtraggio delle frasi. Dalla raccolta iniziale di 10.000 articoli, sono state escluse le frasi prive di entità lessicali riconosciute, riducendo il corpus a 53.400 frasi.

La fase successiva ha riguardato la classificazione delle frasi. Ogni frase è stata etichettata in base alla rilevanza delle sue sequenze di entità lessicali. Questa annotazione è stata realizzata da un gruppo di 16 annotatori con competenze in ambito aziendale e finanziario, che hanno categorizzato le frasi come positive, negative o neutrali.

Infine, per ottenere un campione rappresentativo e gestibile, è stata effettuata la selezione del campione finale. Dalle 53.400 frasi etichettate, è stato estratto casualmente un sottoinsieme di 4846 frasi, con l'obiettivo di rappresentare l'intero database [3].

La Tabella 1 sintetizza le caratteristiche del dataset.

Numero di frasi	4846
Classi di sentiment	Positive, Negative, Neutral
Fonti delle frasi	Notizie in lingua inglese relative alle aziende quotate in OMX Helsinki
Variabili	Lable, Text

Table 1: Caratteristiche principali del dataset.

2.3 Distribuzione delle Classi di Sentiment

Il dataset è composto da tre classi di sentiment: *positive*, *negative* e *neutral*. Tuttavia, come è possibile osservare nella Tabella 2 e successivamente nella Figura 1, la distribuzione delle classi che risulta squilibrata, con una predominanza marcata della classe *neutral*.

Questo aspetto rappresenta un potenziale fattore critico, in quanto un'eccessiva rappresentazione di una classe può introdurre bias nei modelli predittivi, portandoli a preferire la classe maggioritaria indipendentemente dal contenuto testuale. La conseguenza di questo squilibrio è il rischio di compromettere le performance del modello di classificazione, in particolare per quanto riguarda l'accuratezza nella predizione delle classi minoritarie (*positive* e *negative*).

Di conseguenza, è necessario valutare l'impiego di tecniche di bilanciamento che verranno analizzate nei paragrafi successivi.

¹<https://www.kaggle.com/datasets/ankurzing/sentiment-analysis-for-financial-news/data>

²Fornitore di fonti di informazione legale, governativa, aziendale e high-tech [1].

³Borsa valori di riferimento per la Finlandia [2]

Classe	Numero di Frasi
Neutral	2879
Positive	1363
Negative	604

Table 2: Distribuzione delle classi di sentiment nel dataset originale.




Figure 1: Distribuzione delle classi di sentiment rappresentata graficamente.

2.4 Analisi della Lunghezza delle Frasi

Un aspetto cruciale per la comprensione approfondita del dataset testuale è l'analisi della distribuzione della lunghezza delle frasi, misurata in numero di caratteri (inclusa la punteggiatura). Questa metrica fornisce indicazioni preziose sia sulla complessità sintattica intrinseca ai dati, sia per orientare la scelta del modello di elaborazione del linguaggio naturale più appropriato. Come è possibile osservare nella Tabella 3, l'analisi statistica sulla lunghezza delle frasi rivela una distribuzione moderatamente dispersa, caratterizzata dalla presenza di alcuni valori estremi (outlier) che si discostano significativamente dalla tendenza centrale.

Il valore massimo registrato di 315 caratteri evidenzia la presenza di frasi particolarmente estese, che possono essere interpretate come outlier rispetto alla distribuzione principale. Queste frasi anomale potrebbero potenzialmente all'introduzione del rumore durante la fase di addestramento del modello, influenzando negativamente la sua capacità di generalizzazione e aumentando il costo computazionale delle operazioni.

Media	128.13 caratteri
Mediana	119 caratteri
Minimo	9 caratteri
Massimo	315 caratteri

Table 3: Statistiche sulla lunghezza delle frasi.

Come si evince dalla Figura 2, la distribuzione della lunghezza delle frasi tende a concentrarsi in un intervallo compreso approssimativamente tra i 100 e i 130 caratteri. Si osserva una frequenza inferiore di frasi significativamente più brevi o, al contrario, eccezionalmente lunghe.




Figure 2: Distribuzione della lunghezza delle frasi nel dataset.

Per approfondire la comprensione della variabilità della lunghezza delle frasi ciascuna delle tre classi di sentiment (*neutral*, *negative*, *positive*), è stata condotta una analisi attraverso i boxplot presentati in Figura 3.




Figure 3: Boxplot delle lunghezze delle frasi per ciascuna classe di sentiment.

Classe	Media	Mediana	Min	Max	Outlier
Neutral	125.07	116	9	315	28
Negative	125.76	118	37	296	4
Positive	135.65	128	24	298	0

Table 4: Statistiche descrittive delle lunghezze delle frasi per classe di sentiment

Dalle statistiche riportate nella Tabella 4, emerge una significativa variabilità nella lunghezza delle frasi tra le diverse classi. In particolare, la classe *neutral* presenta un numero consistente di outlier, mentre la classe *positive* tende a includere frasi mediamente più lunghe rispetto alle altre. Queste peculiarità suggeriscono che, nelle successive fasi di preprocessing e modellazione, potrebbe essere utile tenerne conto per ottimizzare le prestazioni del modello e migliorare la gestione delle differenze stilistiche tra le classi.

2.5 Analisi della frequenza delle parole

È stata effettuata un'analisi della frequenza delle parole presenti nel dataset originale, identificare la presenza di termini ad alta frequenza e valutare il livello di rumore linguistico presente nei dati grezzi.

Come evidenziato nel grafico in Figura 4, le parole più frequenti includono numerosi termini funzionali come articoli (the, a), congiunzioni (and, but), preposizioni (to, of, in) e altre stopwords comuni. Sebbene queste parole siano grammaticalmente necessarie, risultano poco informative per il compito di sentiment analysis, in quanto non veicolano contenuto semantico rilevante per distinguere tra sentimenti positivi, negativi o neutri.




Figure 4: Top 30 parole più frequenti nel dataset originale.

3 DATA PREPARATION

La fase di Data Preparation ha avuto l'obiettivo di trasformare il testo grezzo del dataset in una forma più pulita e coerente, adatta all'analisi e alla modellazione del sentiment. L'intero processo è stato pensato per ridurre il rumore presente nei dati e semplificare la variabilità linguistica, in modo da facilitare l'individuazione di pattern utili per la classificazione.

Tutto è iniziato con il caricamento del dataset, originariamente in formato CSV, all'interno di un DataFrame 'pandas'. Da qui è cominciata la normalizzazione del testo: tutte le frasi sono state convertite in minuscolo per uniformare le rappresentazioni e rendere irrilevante la distinzione tra lettere maiuscole e minuscole.

Successivamente, sono stati rimossi numeri, segni di punteggiatura ed elementi non testuali tramite espressioni regolari con il modulo 're'. In questo modo, il focus dell'analisi è stato spostato interamente sul contenuto linguistico. È seguita la rimozione delle stopwords, ovvero quelle parole molto frequenti ma poco informative (come articoli, preposizioni, ecc.), utilizzando l'elenco fornito dalla libreria 'nltk'.

Il testo è stato poi tokenizzato, ovvero suddiviso in parole, e successivamente lemmatizzato con il lemmatizzatore di WordNet. Questa operazione ha permesso di ricondurre ogni parola alla sua forma base, riducendo così la complessità del vocabolario e migliorando la generalizzazione dei modelli.

Tutte queste operazioni sono state integrate in una funzione di preprocessing apposita, applicata in modo efficiente all'intero dataset tramite il metodo `.apply()` di 'pandas', producendo una nuova colonna con il testo pulito, `cleaned_text`.

Al termine della fase, il dataset preprocessato è stato salvato nuovamente in formato CSV, pronto per le successive analisi.

Pulizia (esclusione frasi troppo corte) EDA post-preprocessing (cosa è cambiato?)

4 DATA PRE-PROCESSING

Il dataset utilizzato in questo progetto contiene notizie di carattere finanziario scritte in lingua inglese, ciascuna associata a un'etichetta di sentiment (*positive, neutral, negative*). Per prepararne il contenuto all'analisi e all'addestramento dei modelli di NLP, sono stati sviluppati e confrontati due approcci distinti di pre-processing testuale:

- un approccio **light**, focalizzato su una pulizia basilare e non invasiva del testo;
- un approccio **completo** (detto anche "aggressivo"), pensato per una normalizzazione avanzata dei testi.

Questa scelta è stata motivata dal desiderio di valutare l'impatto di differenti livelli di pulizia sulla performance dei modelli di classificazione del sentiment.

4.1 Pre-processing completo (aggressivo)

L'approccio completo prevede una sequenza di trasformazioni strutturate, pensate per ridurre la variabilità testuale e normalizzare numeri, simboli e strutture linguistiche complesse. La Tabella 5 riepiloga i passaggi applicati.

Operazione	Descrizione
<i>Lowercasing</i>	Conversione dell'intero testo in minuscolo.
<i>Separazione lettere-numeri</i>	Espressioni come eur131m diventano eur 131 m.
<i>Normalizzazione intervalli numerici</i>	Intervalli come 2009-2012 diventano NUM - NUM.
<i>Sostituzione valute</i>	Termini come euro, usd, \$, ecc. vengono sostituiti con il token CUR.
<i>Normalizzazione percentuali</i>	Percentuali come 10% o 3, 2% diventano NUM_PERCENT.
<i>Sostituzione numeri</i>	Tutti i numeri vengono sostituiti con il token NUM.
<i>Rimozione punteggiatura</i>	Tutti i caratteri non alfanumerici vengono rimossi.
<i>Tokenizzazione</i>	Eseguita con il tokenizer punkt di NLTK.
<i>Rimozione stopwords</i>	Eliminazione delle parole vuote tramite la lista di NLTK.
<i>Lemmatizzazione</i>	Conversione delle parole alla loro forma base con WordNetLemmatizer.

Table 5: Passaggi del pre-processing completo (aggressivo)

Infine, sono stati rimossi i testi la cui lunghezza risultava inferiore a tre parole dopo il pre-processing, al fine di evitare l'uso di input troppo poveri di contenuto informativo.

Il testo pre-processato è stato aggiunto al dataset come una nuova colonna denominata "cleaned_text". Il dataset è stato successivamente salvato in formato CSV e utilizzato nelle fasi successive.

4.2 Pre-processing leggero (light)

L'approccio light è stato progettato per applicare una pulizia basilare del testo, utile in particolare per metodi di topic modeling come

BERTopic, dove un'eccessiva normalizzazione può ridurre la qualità semantica. I passaggi sono descritti nella Tabella 6.

Operazione	Descrizione
<i>Rimozione spazi extra</i>	Gli spazi multipli vengono ridotti a uno solo.
<i>Rimozione caratteri non ASCII</i>	Caratteri non appartenenti allo standard ASCII (es. simboli o accenti) vengono eliminati.
<i>Sostituzione simboli valuta</i>	I simboli \$, €, £ vengono sostituiti con il token CUR.
<i>Normalizzazione percentuali</i>	Percentuali come 5.5% o 12% diventano NUM_PERCENT.
<i>Sostituzione numeri</i>	Tutti i numeri interi o decimali vengono sostituiti con il token NUM.

Table 6: Passaggi del pre-processing leggero

Anche in questo caso, sono stati eliminati i testi troppo brevi (meno di tre parole). Il risultato è un dataset coerente ma meno trasformato, con la struttura testuale quasi invariata rispetto all'originale.

Confronto e motivazioni. Il pre-processing completo è stato pensato per modelli di classificazione dove la generalizzazione è importante, mentre l'approccio leggero è più adatto ad algoritmi sensibili al contesto e alla struttura sintattica del testo originale. Entrambi i dataset sono stati impiegati nelle fasi successive per confrontare le performance ottenute con diversi modelli di NLP.

5 ANALISI ESPLORATIVA POST-PREPROCESSING

Al termine del pre-processing, è stata condotta un'analisi esplorativa (EDA) per valutare l'impatto delle trasformazioni applicate al testo e confrontare le principali caratteristiche statistiche del dataset.

5.1 Verifica delle normalizzazioni

Una delle priorità era assicurarsi che la sostituzione dei pattern numerici e simbolici (valute, percentuali, numeri) fosse avvenuta correttamente. Sono stati selezionati manualmente alcuni esempi di notizie contenenti numeri, valute o percentuali, confrontando il testo originale con quello preprocessato.

Testo originale	Testo preprocessato
"...net sales doubled to EUR131m from EUR76m..."	"net sale doubled CUR 131m CUR 76m"
"...profit margin of 10% - 20% of net sales..."	"profit margin NUM_PERCENT NUM_PERCENT net sale"
"...rose to EUR 13.1 mn from EUR 8.7 mn..."	"rose CUR NUM mn CUR NUM mn..."

Table 7: Esempi di sostituzioni corrette nel testo

Come evidenziato in Tabella 7, i token NUM, CUR e NUM_PERCENT sono stati correttamente applicati al posto dei corrispondenti elementi originali.

5.2 Distribuzione della lunghezza dei testi

Per valutare l’omogeneità dei testi preprocessati, è stata analizzata la distribuzione della lunghezza (in caratteri) dei contenuti nella colonna cleaned_text. La Figura 5 mostra l’istogramma relativo.




Figure 5: Distribuzione della lunghezza dei testi dopo il pre-processing

Le statistiche principali osservate sulla lunghezza dei testi sono:

- **Media:** 95.02 caratteri
- **Mediana:** 87 caratteri
- **Minimo:** 13 caratteri
- **Massimo:** 291 caratteri

In Tabella 3 sono presenti le stesse statistiche, ma prima del pre-processing.

Dal confronto emerge una riduzione complessiva della lunghezza dei testi:

- la **media** è diminuita di circa il 26%;
- anche la **mediana** è calata, segno che la trasformazione ha agito in modo diffuso su tutto il corpus;
- il **minimo** è aumentato, poiché sono stati rimossi i testi troppo brevi dopo il pre-processing;
- il **massimo** è leggermente diminuito, ma sono stati preservati anche i testi più lunghi.

Questa riduzione è giustificata dall’eliminazione di stopwords, punteggiatura, simboli e dalla normalizzazione di entità numeriche e valutarie, che tendono a comprimere la rappresentazione testuale mantenendo però l’informazione semantica utile al modello.

5.2.1 Analisi per classe di sentiment. L’effetto del pre-processing è stato analizzato separatamente per ciascuna classe (neutral, negative, positive). La Tabella 8 riassume i dati più rilevanti.

Classe	Media originale (parole)	Media preprocessato (parole)
Neutral	22	11
Negative	24	12
Positive	25	13

Table 8: Confronto lunghezza media delle frasi per classe (prima/dopo)

Classe Neutral. La lunghezza media delle frasi si riduce da 22 a 11 parole. Il numero di outlier resta costante (27), ma le frasi risultano più compatte e meno ridondanti.

Classe Negative. Le frasi passano in media da 24 a 12 parole. Gli outlier si riducono sensibilmente, confermando una maggiore regolarità. Frasi molto lunghe (oltre 50 parole) vengono eliminate o contratte.

Classe Positive. Anche qui la lunghezza media si dimezza, da 25 a 13 parole. Il preprocessing preserva comunque frasi fino a 32 parole, mantenendo quindi una buona informatività.




Figure 6: Violin plot: distribuzione frasi - originale vs preprocessato

La Figura 6 mostra graficamente gli effetti del pre-processing sulle singole classi confrontando la distribuzione della lunghezza delle frasi prima e dopo la pulizia del corpus.

Considerazioni. Il pre-processing ha ridotto la lunghezza media in tutte le classi, eliminando parole ridondanti o di scarso valore informativo (es. stopwords). Ciò favorisce modelli NLP più efficienti e meno sensibili al rumore testuale. La struttura sintattica generale è preservata, e l’informazione semantica essenziale risulta concentrata.

5.3 Parole più frequenti nel corpus preprocessato

Dopo l’applicazione del pre-processing completo, è stata calcolata la frequenza delle parole nel nuovo corpus. La Figura 7 mostra le 30 parole più ricorrenti nel dataset preprocessato.

Tra le parole più frequenti emergono con grande evidenza i token speciali introdotti nel pre-processing:

Numero di Topic per Sentiment Dominante (> 50%)

Sentiment Dominante	Numero di Topic
neutral	83
positive	16
mixed	13
negative	9

È stata esaminata la natura dei documenti assegnati al cluster di outlier, ovvero quei testi che BERTopic non è riuscito ad associare in modo coerente a uno dei topic principali. L'obiettivo era verificare se tali frasi presentassero caratteristiche linguistiche differenti, in particolare in termini di lunghezza del testo. L'analisi, basata su un boxplot comparativo in Figura 10, ha mostrato che non vi sono differenze significative tra gli outlier e i non-outlier in termini di lunghezza media del testo (13.49 vs 13.46 parole). Questo suggerisce che l'isolamento di tali frasi non è attribuibile a una struttura testuale anomala, ma piuttosto a contenuti semantici poco affini ai topic principali o a una maggiore ambiguità lessicale.

Figure 10: Boxplot comparativo delle lunghezze delle frasi appartenenti ai cluster Outlier e Non Outlier.

Per comprendere meglio la natura semantica dei documenti classificati come outlier (topic -1), è stata effettuata un'analisi lessicale delle parole più frequenti visibile in Figura 11, confrontando il vocabolario dei testi outlier con quello dei non-outlier. Entrambi i gruppi presentano alcune parole comuni, come "num", "cur", "company", "said" e "finnish", ma con frequenze differenti: ad esempio, la parola "num" compare 1489 volte tra gli outlier e 4220 tra i non-outlier, mantenendo tuttavia una posizione dominante in entrambi i casi.

Tuttavia, nei testi assegnati a topic coerenti (non-outlier), emergono con maggiore chiarezza parole legate a concetti economico-finanziari specifici, come "sale", "profit", "share", "operating", "period" e "market". Al contrario, i topic outlier mostrano una maggiore ricorrenza di termini generici ("business", "new", "group", "oyj"), che potrebbero indicare una mancanza di contesto o una struttura informativa più debole. Questo risultato suggerisce che gli outlier non sono solo semanticamente eterogenei, ma potenzialmente anche meno informativi o contestualmente ambigui, rendendo più difficile per l'algoritmo associarli a un topic coerente.

6.2 Analisi spaziale degli embedding

Al fine di indagare la struttura semantica del corpus da una prospettiva geometrica, è stata condotta un'analisi spaziale degli embedding testuali. A tale scopo, ciascuna frase preprocessata è stata convertita in un vettore numerico attraverso il modello all-MiniLM-L6-v2 della libreria SentenceTransformer, che fornisce una rappresentazione densa e semantica del testo basata su transformer leggeri.

Per rendere visibile la distribuzione dei documenti nel piano, gli embedding sono stati proiettati in due dimensioni tramite la tecnica UMAP (Uniform Manifold Approximation and Projection), utilizzando la metrica del coseno e mantenendo `n_neighbors=15`. Il risultato è stato visualizzato mediante uno scatterplot bidimensionale, in cui ciascun punto rappresenta una frase del corpus, colorata in base alla sua appartenenza al topic outlier (in rosso) o a uno dei topic coerenti (in verde).

Dal grafico in Figura ?? emerge che i documenti classificati come outlier risultano generalmente più dispersi e isolati rispetto ai punti associati a topic ben definiti, che tendono a formare agglomerati compatti. Sebbene siano presenti alcuni piccoli gruppi di embedding outlier vicini tra loro, la loro numerosità risulta insufficiente per generare un topic coerente. Questo comportamento conferma che l'assegnazione a un topic outlier non è riconducibile né alla lunghezza del testo né alla frequenza di termini specifici, ma piuttosto alla posizione nel contesto semantico globale del corpus. In altre parole, la classificazione come outlier riflette una distanza semantica rispetto ai nuclei tematici dominanti, evidenziando frasi che non si integrano facilmente in cluster concettualmente omogenei.

A completamento dell'analisi semantica, è stata visualizzata la distribuzione spaziale dei topic generati da BERTopic proiettando gli embedding testuali nel piano bidimensionale tramite UMAP. A differenza della precedente visualizzazione, in questo caso ciascun punto è stato colorato in base al topic di appartenenza, al fine di analizzare la coerenza interna e la separazione tra i diversi cluster semantici.

Dal grafico in Figura 13 emergono alcune considerazioni interessanti. In primo luogo, i colori tendono a formare regioni compatte e ben separate, soprattutto lungo i margini della mappa. Questo comportamento suggerisce che BERTopic ha segmentato il corpus in maniera coerente dal punto di vista semantico, assegnando molte frasi a topic caratterizzati da un'alta coesione interna. Tali aree possono essere interpretate come topic forti, ovvero gruppi di documenti che condividono un contenuto tematico fortemente omogeneo.

Tuttavia, nella zona centrale della mappa si osserva la presenza di regioni meno definite, in cui i topic si sovrappongono parzialmente o si collocano a distanza ravvicinata. Questo fenomeno è tipico di frasi che trattano argomenti simili o contigui, e riflette una vicinanza semantica tra topic differenti. In prospettiva, tale informazione potrebbe essere sfruttata per unificare automaticamente i topic semanticamente adiacenti, migliorando la sintesi e riducendo la frammentazione dell'output.

Per valutare la coerenza emotiva dei topic identificati, è stata condotta un'analisi della polarizzazione del sentiment all'interno di ciascun cluster. È stata calcolata, per ogni topic, la distribuzione percentuale delle etichette di sentiment (positivo, negativo, neutrale) e determinato il sentiment dominante, ovvero la classe con la frequenza più alta. In seguito, sono stati selezionati i topic in cui una singola etichetta superava la soglia dell'80%, indicativi di un'elevata omogeneità interna in termini di polarità emotiva.

I risultati, visualizzati tramite una heatmap visibile in Figura 14 e sintetizzati nella Tabella 9 ordinata per grado di polarizzazione, mostrano che diversi topic presentano una chiara dominante emotiva, con percentuali superiori anche al 90%. Questi topic possono essere interpretati come cluster tematici coerenti non solo semanticamente, ma anche sul piano del sentiment, e possono costituire una base solida per attività di classificazione supervisionata o generazione di etichette automatiche.

Tale polarizzazione risulta particolarmente evidente nei topic associati a eventi fortemente positivi (es. acquisizioni, utili superiori alle attese, annunci di dividendi) o negativi (es. licenziamenti, perdite operative, revisioni al ribasso). Viceversa, i topic più generici o descrittivi tendono a mostrare una distribuzione più bilanciata delle etichette, riflettendo la natura neutra dell'informazione contenuta.

Topic	Sentimento Dominante	Percentuale Dominante	Numero occorrenze
36	Neutrale	100.00%	30
105	Neutrale	100.00%	13
77	Neutrale	100.00%	17
49	Positivo	100.00%	26

Table 9: Topic con polarizzazione sentimentale dominante.

A completamento dell'analisi sulla polarizzazione dei topic, è stato effettuato un confronto lessicale tra alcuni dei cluster con sentiment dominante ben definito. In particolare, sono stati analizzati i topic 36 (neutrale), 41 (negativo) e 49 (positivo), con l'obiettivo di identificare eventuali parole in comune tra gruppi apparentemente opposti sul piano emotivo.

I risultati mostrano che, nonostante la polarità differente, esistono sovrapposizioni lessicali significative. Ad esempio, il topic 41 (negativo) condivide 16 parole con il topic 49 (positivo), tra cui termini come *quarter*, *net*, *profit*, *mn*, *operating* e *income*, tutti appartenenti al vocabolario tecnico-finanziario. Queste parole, pur essendo comuni nei resoconti economici, possono assumere connotazioni diverse a seconda del contesto narrativo e delle strutture sintattiche circostanti.




Figure 11: Distribuzione delle parole del vocabolario dei testi outlier con quello dei non-outlier.




Figure 12: Distribuzione UMAP – outlier vs non-outlier.




Figure 13: Distribuzione UMAP – frasi colorate per topic.




Figure 14: Heatmap della distribuzione percentuale delle etichette di sentiment per ogni topic.

Anche tra i topic neutrale (36) e positivo (49), sono presenti 5 termini ricorrenti, come net, sale, group e NUM. Il topic neutrale

condivide invece solo 4 parole con quello negativo. Questo conferma che la co-occorrenza di termini tecnici non implica necessariamente una coerenza nel sentiment, sottolineando la necessità di modelli in grado di interpretare non solo il lessico, ma anche le relazioni semantiche più profonde e il contesto narrativo.

7 GENERAZIONE DEGLI EMBEDDING

Il testo, in quanto sequenza di caratteri, non può essere direttamente interpretato da modelli di apprendimento automatico, che operano su vettori numerici. Per questo motivo, è necessario trasformare ogni frase del dataset in una rappresentazione vettoriale numerica chiamata *embedding*. Gli embedding permettono di catturare informazioni sintattiche, semantiche e strutturali del testo in forma matematica, rendendo possibile l'addestramento di modelli di classificazione.

7.1 Scelta del dataset

All'inizio del processo è stato implementato un controllo automatico del path per selezionare quale versione del dataset utilizzare

(preprocessamento **light** oppure **aggressivo**), così da consentire confronti coerenti in fase di classificazione.

7.2 Tecniche di embedding utilizzate

Sono stati generati quattro tipi diversi di embedding, ciascuno con caratteristiche e finalità specifiche:

- **Word2Vec**: ogni frase è rappresentata dalla media dei vettori delle parole contenute, calcolata da un modello pre-addestrato. Le parole fuori vocabolario vengono ignorate.
- **BERT (base)**: per ogni frase si estrae il vettore corrispondente al token speciale [CLS] dello strato finale del modello bert-base-uncased, come sintesi del significato globale.
- **SBERT (Sentence-BERT)**: fornisce direttamente embedding a livello di frase. È ottimizzato per compiti di classificazione e clustering, e riduce sensibilmente il costo computazionale rispetto a BERT standard.
- **FinBERT**: modello BERT addestrato su corpora finanziari. Consente una rappresentazione semantica più adatta ai testi di dominio economico.

7.3 Salvataggio degli embedding

Tutti gli embedding sono stati salvati in formato .npy (NumPy array binari). Questa scelta è motivata da esigenze di efficienza:

- il formato binario è molto più veloce da leggere e scrivere rispetto a .csv;
- consente il salvataggio diretto di array multidimensionali senza conversioni;
- evita problemi legati alla formattazione dei valori numerici (es. separatori decimali, encoding).

Gli embedding così salvati sono stati successivamente ricaricati nella fase di addestramento dei modelli di classificazione.

7.4 Caratteristiche comparate delle tecniche

La Tabella 10 riepiloga le principali caratteristiche delle tecniche di embedding utilizzate.

Tecnica	Dim. Vettore	Livello	Tipo
Word2Vec	300	Parola / Frase (media)	Denso
BERT	768	Frase (token [CLS])	Denso
SBERT	384	Frase	Denso
FinBERT	768	Frase (token [CLS])	Denso

Table 10: Confronto tra tecniche di embedding

- **Livello**: indica se l'embedding è ottenuto parola per parola o sull'intera frase.
- **Tipo**: tutti i metodi producono array numerici densi (*dense vectors*), ideali per modelli MLP o SVM.

7.5 Finalità

L'utilizzo di più tecniche di embedding consente di confrontare l'impatto della rappresentazione testuale sulla performance di modelli di classificazione (SVM, Random Forest, MLP). Inoltre, permette di analizzare se modelli semantici più sofisticati (come FinBERT o

SBERT) offrano vantaggi concreti rispetto ad approcci più semplici ma rapidi (come Word2Vec).

8 MODELLI BASELINE E ADDESTRAMENTO

Dopo aver generato gli embedding testuali, sono stati addestrati diversi modelli di classificazione supervisionata. Lo scopo non è ottenere prestazioni ottimali, ma stabilire dei **modelli baseline** con cui confrontare approcci più sofisticati nelle fasi successive. Questi modelli offrono un primo riferimento per valutare l'efficacia delle rappresentazioni testuali e delle feature disponibili.

8.1 Preparazione dei dati

Scelta del dataset. In fase iniziale viene verificata la presenza del dataset con preprocessing **light** o **aggressivo**, e caricato dinamicamente in base alla sperimentazione da eseguire.

Encoding della label. La colonna label contiene valori testuali (*positive, neutral, negative*), che devono essere convertiti in valori numerici per poter essere interpretati dai modelli. A questo scopo è stato utilizzato un LabelEncoder di sklearn, che assegna un intero univoco a ciascuna classe.

Inclusione della feature topic. Il training dei modelli è stato eseguito sia con che senza questa feature, per verificare se l'aggiunta del topic migliorasse la capacità predittiva del modello. I topic sono stati rappresentati come numeri interi e concatenati agli embedding solo quando previsto.

8.2 Embedding e split dei dati

Gli embedding salvati in formato .npy sono stati caricati in memoria e, se necessario, arricchiti con la colonna topic. Successivamente i dati sono stati suddivisi in training e validation set tramite train_test_split con una suddivisione standard 80/20.

8.3 Modelli utilizzati

Sono stati selezionati quattro modelli di classificazione noti per le loro buone prestazioni in contesti baseline:

- **Logistic Regression (LogReg)**
- **Support Vector Machine (SVM)**
- **Random Forest (RF)**
- **Multilayer Perceptron (MLP)**

8.4 Standardizzazione delle feature

Per modelli sensibili alla scala delle feature (come LOGREG, SVM e MLP), è stata applicata la **standardizzazione** tramite StandardScaler. Questa trasformazione porta ogni feature a media zero e varianza unitaria, condizione che migliora la convergenza dell'ottimizzazione e stabilizza il training.

8.5 Valutazione e confronto dei modelli

Ogni modello è stato valutato tramite le seguenti metriche:

- **Accuracy**
- **Precision**
- **Recall**
- **F1-score**

I risultati sono stati raccolti in un unico DataFrame e ordinati in modo decrescente rispetto all'**accuracy**, per identificare il miglior classificatore.

La Figura 15 mostra un confronto tra i modelli baseline in termini di **accuracy**, includendo diverse combinazioni di embedding e l'eventuale presenza della feature topic.




Figure 15: Confronto tra modelli e tecniche di embedding (ordinati per accuracy)

Dall'analisi emergono alcune osservazioni interessanti:

- Il **modello con le migliori performance** è un SVM addestrato su embedding FinBERT **senza** l'aggiunta della feature topic, con un'accuracy pari all'84.93%.
- FinBERT si dimostra complessivamente l'embedding più efficace, con ottimi risultati anche in combinazione con MLP, Random Forest e con la feature topic.
- L'aggiunta del topic non garantisce un miglioramento sistematico: in alcuni casi migliora leggermente la performance (es. MLP con FinBERT), ma in altri può addirittura ridurre la precisione, indicando che il topic potrebbe introdurre rumore o ridondanza.
- Modelli con embedding Word2Vec risultano significativamente meno efficaci, anche con l'aggiunta del topic, suggerendo che tecniche più dense e contestuali sono preferibili in questo task.

8.6 Miglior modello e matrice di confusione

Il modello con la migliore accuracy è stato ricalibrato e rieseguito sull'intero dataset di test, al fine di generare la relativa **matrice di confusione**, utile a visualizzare gli errori commessi tra le classi.

La Figura 16 mostra la matrice di confusione ottenuta rieseguendo il miglior modello (SVM + FinBERT) sul test set.

- La classe **neutral** è la più facilmente riconoscibile, con 534 istanze correttamente classificate. Tuttavia, presenta anche sovrapposizioni con entrambe le altre classi.
- Le classi **positive** e **negative** vengono in parte confuse con la **neutral**, in particolare le frasi positive (75 errori).
- Gli errori **positivi** $\leftrightarrow$ **negativi** sono molto rari, indicando che il modello riesce a distinguere bene sentimenti opposti, mentre fatica a separare sentimenti chiari da quelli più sfumati o descrittivi.




Figure 16: Matrice di confusione per il miglior modello (SVM + FinBERT)

Nota bene: i risultati riportati sono stati ottenuti utilizzando il dataset sottoposto a **pre-processing leggero**. La medesima pipeline è stata successivamente applicata anche al dataset con **pre-processing aggressivo**, ma in questo caso le prestazioni sono risultate inferiori. Pertanto, nel presente documento vengono mostrati esclusivamente i risultati relativi al **pre-processing light**.

Conclusioni preliminari. FinBERT si dimostra particolarmente efficace in un contesto finanziario, grazie alla sua specializzazione sul dominio. I modelli baseline, in particolare SVM e MLP, offrono prestazioni già solide e rappresentano una base affidabile per confronti con modelli più avanzati nelle fasi successive del progetto. L'inclusione del topic come variabile aggiuntiva ha prodotto risultati contrastanti: in alcuni casi ha migliorato lievemente le performance, ma in molti altri non ha apportato benefici significativi, arrivando persino a peggiorare le metriche rispetto allo stesso modello addestrato senza topic. Questo suggerisce che l'informazione tematica, almeno nella forma in cui è stata incorporata, non rappresenta un forte discriminatore per il compito di sentiment analysis.

9 MODELLI PRE-ADDESTRATI: INFERENZA E FINE-TUNING

Oltre ai modelli baseline addestrati su embedding statici, è stata esplorata una seconda strategia che sfrutta modelli transformer **pre-addestrati** per la sentiment analysis. Questa parte del progetto è suddivisa in due fasi: una prima di **inferenza diretta** (zero-shot) e una successiva di **fine-tuning supervisionato** sul dataset specifico.

9.1 Inferenza con modelli pre-addestrati

Sono stati testati cinque modelli pre-addestrati disponibili tramite la libreria Transformers di HuggingFace. L'obiettivo era verificare le performance **senza alcun riaddestramento**, sfruttando direttamente le conoscenze linguistiche già acquisite.

Motivazione. L'inferenza con modelli pre-addestrati consente di ottenere predizioni a partire dal **testo raw originale**, senza necessità di calcolare manualmente gli embedding. Questo è possibile perché tali modelli incorporano internamente tokenizer, layers di embedding e testate di classificazione. In altre parole, il modello riceve la frase testuale completa ed elabora automaticamente la rappresentazione vettoriale necessaria per classificare il sentiment.

Valutazione. Per garantire coerenza con gli esperimenti precedenti, è stato utilizzato lo stesso test set dei modelli baseline. Ogni modello è stato valutato tramite le metriche standard: **accuracy**, **precision**, **recall**, **F1-score**. I risultati sono stati raccolti in un DataFrame ordinato per accuracy e visualizzati nella Figura 17.




Figure 17: Accuracy dei modelli pre-addestrati su test set (senza fine-tuning)

Il miglior modello in questa fase è risultato essere `mrm8488/deberta-v3-ft-financial-news-sentiment-analysis`, ottenendo un'accuracy quasi perfetta del 98,97%.

Analisi degli errori. Come per i modelli baseline, è stata calcolata la matrice di confusione del miglior modello (Figura 18) per analizzare quali classi venivano confuse più frequentemente. Essa mostra un'elevata accuratezza su tutte le classi, con pochissimi errori. Le uniche confusioni si osservano in classe *neutral*, che tende a sovrapporsi leggermente con *positive*. Nessuna istanza di sentiment negativo è stata erroneamente classificata come positivo e viceversa, a conferma di una chiara distinzione tra polarità opposte.

9.2 Fine-Tuning supervisionato

Dopo l'inferenza zero-shot, si è proceduto a un **fine-tuning supervisionato** del miglior modello (`deberta-v3-ft`) sul dataset annotato. L'obiettivo era adattare ulteriormente il modello al dominio e al task specifico.

Strategia. Durante il fine-tuning:

- Tutti i layer interni del modello sono stati **congelati**, eccetto la *classification head*, per limitare l'overfitting e ridurre il tempo di addestramento.
- Il dataset è stato diviso in training e validation set (stratificato) e convertito in formato Dataset HuggingFace.
- È stato utilizzato Trainer con EarlyStopping e DataCollatorWithPadding.




Figure 18: Matrice di confusione per il miglior modello pre-addestrato (fase inferenza)

Monitoraggio. L'andamento della loss (Figura 19) mostra un iniziale miglioramento su entrambe le curve. Tuttavia, dopo 6 epoche, grazie all'early stopping (pazienza 3), l'allenamento è terminato a causa del peggioramento della *validation loss* che nella maggior parte dei casi indica l'inizio dell'overfitting del modello (il modello si adatta troppo ai dati di training).



Figure 19: Andamento della training e validation loss durante il fine-tuning

Analisi degli errori. La nuova matrice di confusione (Figura 20) mostra che il comportamento del modello è rimasto quasi invariato: infatti, il numero di predizioni corrette e di errori (10) sono gli stessi rispetto a prima, l'unica differenza è dove il modello sbaglia e predice correttamente.

Infine, sono stati analizzati manualmente alcuni esempi in cui il modello sbagliava la predizione. Questo ha permesso di evidenziare limiti legati all'ambiguità semantica, alla presenza di frasi neutre




Figure 20: Matrice di confusione dopo il fine-tuning del modello pre-addestrato

ma sintatticamente complesse, o a contesti finanziari altamente specialistici. La tabella 11 mostra un esempio di errore fatto dal modello:

Testo Originale	Label Reale	Label Predetta
So far the company has awarded more than \$350,000 worth of tools and materials.	Neutral	Positive
A maximum of 20 employees , who work in Karttakeskus and are responsible for producing Geographic Information Services , will be affected , the company added.	Neutral	Negative

Table 11: Esempi di classificazione errata da parte del modello fine-tunato

Osservazioni:

- **Esempio 1 – Falso positivo:** la frase riporta un’informazione neutra (assegnazione di strumenti), ma l’uso di parole come *awarded* e l’alto valore monetario (\$350,000) può aver indotto il modello ad associare un sentiment positivo. Questo suggerisce che il modello è sensibile a keyword numeriche e verbali che, in contesti non emotivi, possono comunque suonare “ottimiste”.
- **Esempio 2 – Falso negativo:** la frase riguarda una riorganizzazione aziendale che impatta un numero limitato di dipendenti. Nonostante l’informazione sia descrittiva, il modello ha probabilmente interpretato termini come *affected* e *maximum of 20 employees* in chiave negativa, sottovalutando l’aspetto neutro e contestuale. Questo tipo di errore è frequente quando il modello non riesce a distinguere tra un rischio effettivo e una semplice descrizione operativa.

Questi esempi mostrano che, sebbene le metriche globali siano ottime, il modello può ancora confondere sfumature linguistiche non legate a un reale sentimento ma solo a parole “caricate” semanticamente.

9.2.1 *Visualizzazione dello spazio degli embedding.* Per comprendere meglio le ragioni alla base degli errori residui del modello, è stata effettuata una proiezione bidimensionale degli **embedding CLS** (token [CLS]), utilizzati dal modello come rappresentazione dell’intera frase per la classificazione.

Interpretazione. Come si osserva dalla Figura 21, ciascun punto rappresenta una frase del test set, codificata nello spazio latente dal modello pre-addestrato. I colori indicano la classe reale (positive, neutral, negative), mentre i simboli rossi (“X”) evidenziano i campioni classificati erroneamente.

Distribuzione e sovrapposizione. La visualizzazione mostra tre principali cluster ben distinti, corrispondenti alle tre classi. Tuttavia, alcuni errori sono localizzati in regioni di **sovrapposizione semantica** tra due classi, dove gli embedding di frasi neutral si avvicinano molto a quelli di classe positiva o negativa. Ciò suggerisce che il modello non ha una separazione netta in quelle aree dello spazio e che **la rappresentazione semantica delle frasi è ambigua o meno definita.**




Figure 21: Proiezione 2D dello spazio degli embedding (CLS) con evidenza degli errori

Questo tipo di analisi conferma che gli errori non sono casuali, ma avvengono in corrispondenza di aree del feature space dove la densità degli embedding di classi diverse si avvicina.

Conclusion. L'utilizzo di modelli pre-addestrati, in particolare DeBERTa-v3 fine-tuned su news finanziarie, ha dimostrato performance superiori rispetto ai modelli baseline. La possibilità di sfruttare direttamente il testo grezzo semplifica notevolmente il flusso di lavoro, ed elimina la necessità di creare embedding manuali o gestire feature ingegnerizzate come il topic. Il fine-tuning ha ulteriormente migliorato le performance, consolidando questo approccio come il più promettente per futuri sviluppi.

Nota bene: i risultati riportati sono stati ottenuti utilizzando il dataset sottoposto a pre-processing leggero. La medesima pipeline è stata successivamente applicata anche al dataset con pre-processing aggressivo, ma in questo caso le prestazioni sono risultate inferiori. Pertanto, nel presente documento vengono mostrati esclusivamente i risultati relativi al pre-processing light.

10 CONCLUSIONI

Nel presente progetto è stato affrontato il compito di **sentiment analysis** su un corpus di notizie finanziarie in lingua inglese, con l'obiettivo di classificare ogni frase in tre classi: *positive*, *neutral*, e *negative*.

Il lavoro si è articolato in diverse fasi, a partire dalla costruzione di una **pipeline di pre-processing**, implementata in due versioni: una leggera e una più aggressiva. Questa scelta ha permesso di confrontare in modo controllato l'impatto della normalizzazione testuale sulle prestazioni dei modelli.

Successivamente, sono state esplorate diverse tecniche di **embedding**, tra cui Word2Vec, BERT, SBERT e FinBERT. Tali rappresentazioni vettoriali sono state impiegate per addestrare una serie di **modelli baseline** supervisionati (SVM, Random Forest,

MLP, Logistic Regression), valutando l'influenza sia dell'embedding scelto, sia dell'eventuale uso del topic come feature aggiuntiva. I risultati hanno mostrato che l'aggiunta del topic non ha migliorato significativamente le prestazioni, e in alcuni casi ha introdotto rumore.

Il miglior modello nella fase baseline è stato una SVM addestrata su embedding FinBERT con pre-processing aggressivo, raggiungendo un'accuracy dell'84.9%.

Successivamente, è stato adottato un approccio più avanzato basato su **modelli transformer pre-addestrati** tramite la libreria Transformers. Nella fase di inferenza zero-shot, il modello deberta-v3-ft ha ottenuto risultati eccellenti già senza alcun ri-addestramento, superando i modelli tradizionali. Il **fine-tuning supervisionato** di tale modello ha portato a performance ulteriormente migliorate, con un'accuratezza prossima al 99% e una distribuzione degli errori molto contenuta.

Infine, è stata condotta un'analisi qualitativa sugli errori residui, con l'ausilio di visualizzazioni dello **spazio latente degli embedding**. Tale analisi ha evidenziato che gli errori si concentrano in zone di sovrapposizione semantica tra classi, suggerendo limiti strutturali legati alla natura ambigua di alcune frasi.

In conclusione, quindi, il progetto ha dimostrato come l'utilizzo di modelli pre-addestrati nel dominio finanziario rappresenti una soluzione altamente efficace per la sentiment analysis.

REFERENCES

- [1] "LexisNexis," <https://www.lexisnexis.com/en-us/gateway.page>.
- [2] "OMX_{Helsinki}," .
P. Malo, A. Sinha, P. Korhonen, J. Wallenius, and P. Takala, "eng-Good debt or bad debt: Detecting semantic orientations in economic texts," *eng Journal of the Association for Information Science and Technology*, vol. 65, no. 4, pp. 782–796, 2014.